Modelo bayesiano de recomendación

Fundamentos, justificación, evaluación y evolución del sistema | 31 de octubre de 2026

1. ¿Qué es un modelo bayesiano?

La inferencia bayesiana combina una creencia inicial (distribución previa o prior) con la evidencia observada para obtener una distribución posterior. En vez de confiar únicamente en frecuencias históricas, permite regularizar las estimaciones cuando existen pocos datos.

En nuestro problema queremos estimar, para dos artículos diferentes, la probabilidad de que un cliente compre el producto j en un ticket que ya contiene el producto i. Es una asociación de co-compra, no una prueba de que ambos productos sean técnicamente compatibles.

2. ¿Por qué escogimos este enfoque?

• Escasez de datos: contamos con 42 tickets y 28 productos. Las frecuencias directas pueden ser 0 % o 100 % simplemente por falta de observaciones.

• Interpretabilidad: cada puntuación puede explicarse mediante el número de tickets, la popularidad del candidato y una regla matemática explícita.

• Implementación ligera: podemos calcular las asociaciones fuera de línea, exportarlas a CSV y servir recomendaciones sin infraestructura de entrenamiento en producción.

• Regularización: el prior Beta reduce estimaciones extremas y facilita el tratamiento de pares poco observados.

Decisión de diseño: preferimos un método probabilístico sencillo y auditable frente a filtrado colaborativo complejo o modelos de aprendizaje profundo, que con este volumen de datos serían difíciles de justificar y validar.

3. Formulación del modelo Beta-Binomial

Definimos N = total de tickets; n_i = tickets que contienen i; n_j = tickets que contienen j; n_{ij} = tickets que contienen ambos. Sea θ_{ij} = P(j presente | i presente).

$$q_j = (n_j + \varepsilon) / (N + 2\varepsilon), \text{ con } \varepsilon = 0.5$$

$$\theta_{ij} \sim \text{Beta}(k \cdot q_j, k \cdot (1 - q_j)), \text{ con } k = 5$$

$$\text{Puntuación} = E[\theta_{ij} \mid \text{datos}] = (n_{ij} + k \cdot q_j) / (n_i + k)$$

El prior se centra en la popularidad general de j. El parámetro k controla cuánto pesa esa información previa frente a los tickets en los que aparece i: un k mayor produce más suavización. La asociación es dirigida: i → j puede diferir de j → i.

Cómo funciona y cómo lo evaluamos

4. Del cálculo a las recomendaciones

El sistema calcula las puntuaciones de los 756 pares dirigidos posibles entre 28 productos distintos y las guarda en Data/asociaciones_modelo.csv. Cuando se consulta un SKU, la API lee las puntuaciones, descarta el producto de origen y los candidatos sin stock, ordena de mayor a menor y devuelve hasta tres sugerencias.

Las relaciones ajustadas manualmente pueden sustituir la puntuación del modelo. En ese caso, el valor mostrado es una puntuación operativa, no necesariamente una probabilidad posterior. La interfaz también evita recomendar artículos que ya están en el carrito.

5. ¿Cómo evaluamos el modelo?

Aplicamos una evaluación retrospectiva leave-one-ticket-out (LOOTO): se retiene un ticket para evaluar, se calculan asociaciones con los demás tickets y se comprueba si los productos recomendados a partir de un artículo del ticket coinciden con los restantes artículos del ticket retenido. Se repite sobre los casos definidos en el notebook.

Se reportaron 89 casos basados en incidencias de productos en tickets. No son 89 observaciones estadísticamente independientes, porque varios casos provienen de un mismo ticket.

Métrica	Bayesiano	Popularidad
Hit Rate@3	0.2697 (24/89)	0.0000
Precision@3	0.0936	0.0000
Recall@3	0.2397	0.0000

Hit Rate@3: proporción de casos en los que al menos una de las tres recomendaciones fue relevante. Precision@3: proporción de recomendaciones acertadas entre las posiciones ofrecidas. Recall@3: proporción de productos relevantes recuperados.

El resultado 24/89 significa que hubo al menos un acierto en 24 de los 89 casos evaluados. La referencia por popularidad obtuvo cero en esta evaluación concreta; no implica que cualquier recomendador de popularidad tenga rendimiento nulo.

6. ¿Qué aprendimos de la sensibilidad del prior?

Se exploraron k = 1, 2, 5, 10 y 20. Los cuatro primeros valores produjeron las mismas métricas reportadas; k = 20 mostró un desempeño menor. Se conservó k = 5 como una elección razonable de suavización, no como un óptimo estadísticamente demostrado.

7. ¿Qué limitaciones tiene la evaluación?

• Muestra pequeña y tickets correlacionados: las métricas son inestables y no permiten conclusiones de significación estadística.

• La evaluación retrospectiva no demuestra impacto en ventas, satisfacción ni aceptación real de las sugerencias.

• Las co-compras pueden reflejar popularidad o hábitos de compra, no compatibilidad técnica ni relaciones causales.

Cómo haríamos el modelo más robusto

8. Mejoras prioritarias, en orden de implementación

1. Datos y calidad. Recopilar más tickets reales con fecha, sucursal, unidades, devoluciones y disponibilidad histórica. Validar duplicados, faltantes, cambios de SKU y sesgos del catálogo. Evitar usar información futura para recomendar en fechas pasadas.

2. Evaluación temporal. Entrenar con compras anteriores y evaluar con un periodo posterior, manteniendo tickets completos como unidad de separación. Reportar métricas por sucursal, categoría, productos nuevos y frecuencia de compra; añadir intervalos de incertidumbre mediante remuestreo por ticket.

3. Comparaciones más exigentes. Evaluar contra popularidad global, popularidad condicionada, reglas de asociación (soporte, confianza y lift) y un ranking simple basado en contenido. Usar exactamente los mismos candidatos, restricciones de stock y particiones para una comparación justa.

4. Prior jerárquico. Sustituir el prior global por información de categoría o familia de producto, con parámetros aprendidos de los datos cuando el volumen lo permita. Así, un producto nuevo podría aprovechar patrones de artículos semejantes sin depender únicamente de su popularidad global.

5. Señales de negocio y compatibilidad. Integrar atributos de materiales, medidas, usos, reglas técnicas, margen, precio y existencias. Mantener separadas las restricciones duras de compatibilidad y las puntuaciones probabilísticas de co-compra.

6. Actualización y trazabilidad. Recalcular asociaciones periódicamente con nuevas ventas, versionar datos y modelo, registrar el origen de cada puntuación y monitorizar cambios de catálogo, cobertura y calidad.

7. Validación en operación. Cuando exista tráfico suficiente, realizar una prueba A/B con métricas de aceptación, conversión incremental, valor de ticket y satisfacción. Una mejora en Hit Rate offline no garantiza un incremento comercial.

9. Conclusión

La solución es un prototipo razonable y auditable para un escenario de datos escasos. Su principal fortaleza es la interpretabilidad; su principal límite es la evidencia disponible para estimar y validar asociaciones. La siguiente etapa no consiste simplemente en usar un algoritmo más complejo, sino en mejorar los datos, la evaluación y las reglas de negocio.

Referencia de implementación: notebooks/01_exploracion_datos.ipynb, Data/asociaciones_modelo.csv y backend/main.py del repositorio público github.com/LucindaSerna/ferreteria-fullstack.